

Proyecto Final — Aprendizaje No Supervisado

Clustering de Países por Indicadores Socioeconómicos y de Salud

Maestría en Inteligencia Artificial — FIUNA

César Núñez

1. Introducción

La clasificación de países según su nivel de desarrollo es un problema de alta relevancia para organismos internacionales, gobiernos y académicos. Las clasificaciones tradicionales — como el Índice de Desarrollo Humano (HDI, por sus siglas en inglés) del Programa de las Naciones Unidas para el Desarrollo (UNDP, por sus siglas en inglés) — son construidas con metodologías predefinidas, variables específicas y criterios establecidos por expertos.

Sin embargo, surge una pregunta natural desde la perspectiva del aprendizaje automático: **¿pueden los algoritmos de clustering descubrir esa misma estructura de forma completamente no supervisada, partiendo únicamente de indicadores socioeconómicos y de salud?** Responder esta pregunta tiene valor tanto metodológico, como validación de las técnicas de clustering y práctico, ya que permitiría identificar perfiles de desarrollo en contextos donde no existen clasificaciones oficiales disponibles.

Este trabajo aborda ese desafío aplicando técnicas de aprendizaje no supervisado sobre un dataset público de indicadores por país, sin utilizar ninguna etiqueta de clasificación durante el proceso. Al finalizar, los grupos descubiertos se comparan contra una referencia internacional para evaluar en qué medida el clustering capturó estructura real de desarrollo humano.

2. Objetivos

- Identificar grupos de países con perfiles similares de desarrollo socioeconómico y salud pública mediante clustering no supervisado.
- Implementar y comparar dos algoritmos de clustering, evaluando su desempeño con métricas internas y externas.
- Evaluar el impacto de las decisiones de preprocesamiento sobre la calidad del clustering.
- Validar externamente los resultados contra una clasificación internacional reconocida.

3. Dataset

El dataset *Country-Level Socioeconomic & Health Data* fue recolectado por HELP International, una organización no gubernamental humanitaria, con datos de aproximadamente 2014–2016. Está disponible públicamente en Kaggle [1]. Contiene **167 países**, **9 indicadores numéricos** y **cero valores faltantes**.

Cuadro 1: Variables del dataset

Variable	Descripción	Unidad
child_mort	Mortalidad infantil (menores de 5 años)	muerter / 1.000 nacidos vivos
exports	Exportaciones de bienes y servicios	% del PIB per cápita
health	Gasto en salud	% del PIB per cápita
imports	Importaciones de bienes y servicios	% del PIB per cápita
income	Ingreso neto per cápita	USD
inflation	Inflación anual	%
life_expec	Esperanza de vida	años
total_fer	Tasa de fertilidad total	hijos por mujer
gdpp	PIB per cápita	USD

4. Análisis Exploratorio de Datos (EDA)

El análisis exploratorio reveló tres características que condicionaron las decisiones de preprocesamiento:

Sesgo en variables económicas. Las variables `gdpp`, `income` y `child_mort` presentan distribuciones con cola larga a la derecha (sesgo de 2.22, 2.23 y 1.45 respectivamente), requiriendo transformación antes del escalado.

Outliers en variables específicas. Se identificaron 8 países con Z-score > 3 en al menos una variable. La mayoría son outliers en una sola dimensión — Singapore y Luxembourg en `exports`, Nigeria y Venezuela en `inflation` — lo que sugiere un tratamiento localizado más que la eliminación de países.

Correlaciones reveladoras. El mapa de correlaciones muestra relaciones fuertes a lo largo del eje de desarrollo humano: `child_mort` y `life_expec` ($r = -0,89$), `total_fer` y `child_mort` ($r = 0,85$). También evidencia redundancia entre `income` y `gdpp` ($r = 0,90$) y correlación nula de `imports` con el desarrollo, ambas determinantes para la selección de variables.




Figura 1: Mapa de correlaciones de Pearson entre los 9 indicadores originales.

5. Preprocesamiento

El preprocesamiento fue una etapa central del trabajo, ya que la calidad del clustering depende directamente de cómo se representan los datos. Se siguieron cuatro pasos en orden: selección de variables, transformación logarítmica, tratamiento de outliers y escalado. Cada decisión fue tomada a partir del análisis exploratorio, no de criterios arbitrarios.

5.1. Selección de variables

A partir de las correlaciones identificadas en el EDA, se eliminaron dos variables:

- **imports**: correlación prácticamente nula con los indicadores de desarrollo ($r_{\text{life}} = 0,05$, $r_{\text{gdpp}} = 0,12$) y principal fuente de outliers en Singapore, Malta y Luxembourg.
- **income**: redundante con **gdpp** ($r = 0,90$). Se retiene **gdpp** por ser el estándar internacional utilizado por el Banco Mundial, el Fondo Monetario Internacional (FMI) y el UNDP.

Las **7 variables finales** cubren: salud (**child_mort**, **life_expec**), economía (**gdpp**), bienestar social (**health**, **total_fer**), apertura comercial (**exports**) y estabilidad macroeconómica (**inflation**).

5.2. Transformación logarítmica

Las variables **gdpp** y **child_mort** presentan distribuciones con cola larga a la derecha, comportamiento típico de indicadores económicos y demográficos a nivel mundial: la mayoría de los países se concentran en valores bajos o medios, mientras que unos pocos casos extremos se alejan significativamente de la media. Este sesgo positivo distorsiona el espacio de características y puede afectar negativamente el clustering, ya que las distancias entre países ricos o con alta mortalidad quedarían sobredimensionadas respecto al resto.

Por ello, se aplica la transformación $\log(1 + x)$, que comprime la escala en los valores altos sin afectar los valores cercanos a cero. El efecto es inmediato: **gdpp** pasa de un sesgo de 2,22 a 0,01, y **child_mort** de 1,45 a 0,07, logrando distribuciones prácticamente simétricas. El resto de las variables no requirieron esta transformación al presentar sesgo dentro de rangos aceptables.

5.3. Tratamiento de outliers

Se identificaron **8 países** con Z-score > 3 en al menos una variable, detallados en la Tabla 2. Estos países no son errores de medición sino casos reales con valores extremos en variables específicas, por ejemplo, Singapore y Luxembourg son outliers en **exports** por ser economías de enclave, mientras que Nigeria y Venezuela lo son en **inflation** por inestabilidad macroeconómica estructural.

Cuadro 2: Países outliers y variables afectadas (Z-score > 3)

País	Variable con Z-score > 3
Haiti	life_expec
Luxembourg	exports
Malta	exports
Niger	total_fer
Nigeria	inflation
Singapore	exports
United States	health
Venezuela	inflation

Se evaluaron tres estrategias de tratamiento:

1. Sin tratamiento — los outliers permanecen con sus valores originales.
2. Separar y reintegrar — los 8 países se excluyen del clustering y se asignan al cluster más cercano por distancia al centroide.
3. **Capping al percentil 95** — los valores extremos se limitan al p95 de cada variable.

La estrategia de **capping al percentil 95** fue seleccionada por producir el mejor Índice de Rand Ajustado (ARI) en la grilla sistemática de pruebas, preservar los 167 países en el análisis y reducir la distorsión sin eliminar información real.

5.4. Escalado

Se aplica `StandardScaler` para estandarizar todas las variables a media = 0 y desviación estándar = 1, asegurando que ninguna variable domine el clustering por diferencias de escala numérica. Se evaluó también `RobustScaler` (más resistente a outliers por naturaleza), pero en combinación con el capping p95 ya aplicado, `StandardScaler` produjo mejores resultados en la validación externa.

6. Reducción Dimensional

Se aplican dos técnicas de reducción dimensional con propósitos distintos. El Análisis de Componentes Principales (PCA, por sus siglas en inglés) se utiliza de forma exploratoria para entender la estructura de varianza del dataset, mientras que t-SNE (*t-distributed Stochastic Neighbor Embedding*) se emplea como visualización principal de los resultados del clustering, al preservar mejor la estructura local del espacio de alta dimensión.

PCA

El primer componente principal (PC1) explica el 56.5% de la varianza total, lo que indica que existe un eje dominante de variación en los datos. Los loadings confirman que este eje captura el nivel de desarrollo humano: `gdp` y `life_expec` tienen cargas negativas, mientras que `child_mort` y `total_fer` tienen cargas positivas. La proyección 2D muestra una disposición continua de los países a lo largo de ese eje, con los países de mayor desarrollo hacia un extremo y los de menor desarrollo hacia el otro, sin fronteras nítidas entre grupos.




Figura 2: Proyección PCA 2D.

t-SNE

t-SNE permite visualizar relaciones no lineales entre países que PCA no captura por su naturaleza lineal. Se exploró el hiperparámetro `perplexity` $\in \{5, 15, 30, 50\}$ y se seleccionó `perplexity` = 30 por producir la proyección más estable y representativa para este tamaño de dataset. La proyección resultante sugiere la existencia de zonas de mayor densidad, aunque sin separaciones abruptas entre ellas, lo que refleja la naturaleza continua y gradual del desarrollo humano a nivel mundial.




Figura 3: Proyección t-SNE final (`perplexity` = 30).

7. Metodología de Clustering

7.1. Selección del número de clusters

La selección de k es una decisión crítica en clustering, ya que no existe un valor universalmente correcto — depende tanto de las métricas estadísticas como de la interpretabilidad de los grupos resultantes. Se evaluaron $k \in \{2, 3, 4, 5, 6\}$ mediante K-Means y tres métricas internas complementarias: el coeficiente de Silhouette, que mide qué tan bien separado está cada punto de su cluster respecto a los demás; el índice de Davies-Bouldin, que penaliza clusters poco compactos o muy cercanos entre sí; y el índice de Calinski-Harabasz, que evalúa la relación entre la dispersión inter e intra-cluster.

Las métricas maximizan en $k = 2$, lo cual refleja la brecha marcada entre países desarrollados y no desarrollados. Sin embargo, $k = 2$ es una partición demasiado gruesa que no captura la diversidad de las economías emergentes ni los países en transición. Por otro lado, a partir de $k \geq 4$ las métricas decaen progresivamente y el balanceo de clusters se deteriora. Se selecciona $k = 3$ como el valor que mejor equilibra calidad estadística, balanceo de clusters e interpretabilidad de los grupos resultantes.

Cuadro 3: Métricas de validación interna para distintos valores de k (K-Means)

k	Silhouette $\uparrow$	Davies-Bouldin $\downarrow$	Calinski-Harabasz $\uparrow$	Mín. cluster
2	0.3471	1.1350	117.33	72
3	0.2717	1.2844	95.96	51
4	0.2522	1.2788	79.19	28
5	0.2565	1.2788	73.33	15
6	0.2544	1.3021	68.37	14

7.2. Baseline: K-Means

K-Means ($k = 3$, `n_init=20`, `random_state=42`) se utiliza como referencia comparativa. El algoritmo minimiza la inercia intra-cluster mediante la asignación iterativa de cada punto al centroide más cercano. Su principal limitación en este contexto es la asunción de clusters esféricos de igual varianza, lo cual no es realista para perfiles de desarrollo que presentan geometrías irregulares y tamaños desiguales. Sirve como punto de comparación para evaluar el aporte de los algoritmos principales.

7.3. Algoritmo 1: Spectral Clustering

Spectral Clustering aborda el problema de agrupamiento desde una perspectiva basada en grafos. A partir de los datos escalados, construye una matriz de similitud entre países utilizando un kernel RBF (función de base radial), donde la similitud entre dos países i y j se define como:

$$w_{ij} = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$$

Esta matriz representa un grafo ponderado donde los países son nodos y las aristas reflejan su grado de similitud. Luego se calcula el Laplaciano normalizado del grafo y se obtienen sus autovectores, proyectando los datos en ese espacio espectral donde las estructuras de clustering son más evidentes. Finalmente se aplica K-Means en ese espacio reducido para obtener las asignaciones finales.

La principal ventaja de este enfoque para el dataset en cuestión es su **robustez ante outliers**: al trabajar sobre similitud global en lugar de distancias euclidianas, los países con valores extremos no distorsionan la estructura de los grupos. Esta propiedad resultó determinante, ya que todos los métodos jerárquicos evaluados (Ward, complete, average) colapsaron en clusters de 1–3 países debido a la presencia de estos casos extremos.

Hiperparámetros: `n_clusters=3`, `affinity=rbf`, `n_init=10`, `random_state=42`.

7.4. Algoritmo 2: Gaussian Mixture Models (GMM)

GMM es un modelo probabilístico que asume que los datos fueron generados por una mezcla de k distribuciones gaussianas multivariadas. Formalmente, la densidad de probabilidad del modelo es:

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k)$$

donde π_k son los pesos de mezcla, μ_k los vectores de media y Σ_k las matrices de covarianza de cada componente. Los parámetros se estiman mediante el algoritmo Expectation-Maximization (EM), que alterna entre calcular las probabilidades de pertenencia de cada punto a cada componente (paso E) y actualizar los parámetros del modelo (paso M).

A diferencia de K-Means y Spectral Clustering, GMM produce **asignaciones blandas** (*soft assignments*): cada país recibe una probabilidad de pertenencia a cada cluster, no una asignación binaria. Esto es especialmente relevante para economías emergentes o países en transición, que comparten características de más de un perfil de desarrollo. Además, la flexibilidad en la forma de las matrices de covarianza (`full`, `tied`, `diag`, `spherical`) permite capturar clusters con geometrías elipsoidales arbitrarias.

La selección de hiperparámetros se realiza mediante el Criterio de Información Bayesiano (BIC), que penaliza la complejidad del modelo para evitar sobreajuste. Se exploraron las cuatro variantes de covarianza y $n \in [2, 9]$ componentes, seleccionando la configuración que minimiza el BIC: `covariance_type=diag, n_components=5`.

8. Resultados

8.1. Spectral Clustering

Spectral Clustering identificó tres perfiles de desarrollo claramente diferenciados.

Cuadro 4: Perfiles por cluster — Spectral Clustering

Perfil	child_mort	life_expec	gdpp (USD)	total_fer	inflation	n
Subdesarrollado	96.8	59.0	939	5.17	11.3 %	39
En desarrollo	29.9	71.0	7.664	2.66	9.9 %	76
Desarrollado	6.6	78.6	29.729	1.70	2.0 %	52

El **cluster subdesarrollado** (39 países) concentra prácticamente toda África Subsahariana, con países como Tanzania, Burkina Faso, Malawi, Mozambique, Mali, Uganda y Gambia. Sus indicadores son los más críticos del dataset: mortalidad infantil promedio de 96.8 muertes por cada 1.000 nacidos vivos, esperanza de vida de apenas 59 años y un PIB per cápita de 939 USD. La tasa de fertilidad de 5.17 hijos por mujer refleja la alta natalidad característica de regiones con acceso limitado a educación y servicios de salud reproductiva. Afghanistan es el único país fuera de África en este grupo, lo que da cuenta de la profundidad de su crisis humanitaria.

El **cluster en desarrollo** (76 países) es el más heterogéneo y el más numeroso, agrupando economías emergentes y países de renta media de América Latina, Asia, Europa del Este y Medio Oriente. Países como Bolivia, Paraguay, Jamaica, Guyana, Egipto y Azerbaijan comparten un perfil intermedio: mortalidad infantil de 29.9, esperanza de vida de 71 años y PIB per cápita de 7.664 USD. Esta heterogeneidad interna es esperable — el grupo captura realidades muy distintas bajo un mismo perfil estadístico, desde economías con instituciones consolidadas hasta países con alta informalidad.

El **cluster desarrollado** (52 países) incluye Europa Occidental, América del Norte, Australia, Japón, Corea del Sur y otros países de alto ingreso. Países como Finlandia, Suecia, Polonia, Croacia y el Reino Unido presentan mortalidad infantil de apenas 6.6, esperanza de vida de 78.6 años y PIB per cápita de 29.729 USD. La inflación promedio de 2.0 % refleja la estabilidad macroeconómica característica de estas economías.

8.2. Gaussian Mixture Models

GMM identificó cinco perfiles mediante el criterio BIC, revelando una granularidad más fina que Spectral Clustering, especialmente dentro del espectro de países con menor desarrollo.

Cuadro 5: Perfiles por cluster — GMM (ordenados por índice de desarrollo)

Perfil	child_mort	life_expec	gdpp	inflation	Certeza	n
Subdesarrollado	99.8	57.7	735	7.0 %	99.5 %	32
Subd. c/ inestabilidad	92.5	63.6	3.736	31.3 %	99.2 %	9
En desarrollo	37.7	68.4	3.412	8.8 %	95.6 %	41
En desarrollo alto	12.4	75.3	12.042	7.0 %	97.2 %	56
Desarrollado	4.2	80.8	44.607	1.5 %	99.7 %	29

El **cluster subdesarrollado** (32 países) concentra los casos más críticos del dataset, con mortalidad infantil promedio de 99.8 y esperanza de vida de 57.7 años. La certeza de asignación del 99.5 % indica que estos países están muy alejados de cualquier otro perfil — no hay ambigüedad en su clasificación. Países como Tanzania, Burkina Faso, Mozambique, Mali y Malawi son los más representativos.

El **cluster subdesarrollado con inestabilidad macroeconómica** (9 países) es el hallazgo más relevante de GMM y la distinción que Spectral Clustering no pudo capturar. Países como Nigeria, Yemen, Angola, Sudán y Congo presentan indicadores de salud igualmente críticos (mortalidad infantil de 92.5) pero con una inflación promedio del 31.3 % — más de cuatro veces la del cluster subdesarrollado estable. Esta diferencia no es menor: la inestabilidad de precios destruye el poder adquisitivo, dificulta la planificación económica y agrava la pobreza estructural. La certeza del 99.2 % confirma que estos países forman un grupo estadísticamente bien definido.

El **cluster en desarrollo** (41 países) agrupa economías de renta media-baja con relativa estabilidad. Bolivia, Bhutan, Guatemala, Egipto, Filipinas y Paraguay comparten un perfil de mortalidad infantil de 37.7 e inflación controlada del 8.8 %, lo que los diferencia claramente del grupo anterior a pesar de tener un PIB per cápita similar (3.412 vs 3.736 USD). La variable determinante aquí no es el ingreso sino la estabilidad económica.

El **cluster en desarrollo alto** (56 países) es el más numeroso de GMM e incluye economías emergentes consolidadas como Chile, Bulgaria, Rumanía, Túnez, Albania y Mauricio. Con mortalidad infantil de 12.4, esperanza de vida de 75.3 años y PIB per cápita de 12.042 USD, estos países se encuentran en una etapa de transición hacia el desarrollo pleno. La certeza del 97.2 % indica cierta heterogeneidad interna — algunos países en los bordes de este grupo comparten características con el cluster desarrollado.

El **cluster desarrollado** (29 países) concentra las economías más avanzadas: Suecia, Finlandia, Austria, Noruega, Dinamarca, Alemania, Islandia y el Reino Unido. Con mortalidad infantil de apenas 4.2, esperanza de vida de 80.8 años, PIB per cápita de 44.607 USD e inflación de 1.5 %, presentan los mejores indicadores en todas las dimensiones. La certeza del 99.7 % — la más alta de todos los clusters — confirma que estos países están estadísticamente muy bien definidos y alejados del resto.

9. Evaluación

9.1. Métricas internas

Las métricas internas evalúan la calidad del clustering sin recurrir a información externa, midiendo la compacidad de los grupos y la separación entre ellos.

Cuadro 6: Comparación de métricas internas

Algoritmo	k	Silhouette $\uparrow$	Davies-Bouldin $\downarrow$	Calinski-Harabasz $\uparrow$
K-Means (baseline)	3	0.2717	1.2844	95.96
Spectral Clustering	3	0.2718	1.2378	92.07
GMM	5	0.1846	1.5426	60.94

Spectral Clustering supera a K-Means en Davies-Bouldin (1.2378 vs 1.2844), indicando que sus clusters son más compactos y están mejor separados entre sí, con prácticamente el mismo coeficiente de Silhouette (0.2718 vs 0.2717). Esta diferencia, aunque pequeña en valor absoluto,

confirma que Spectral Clustering produce una partición geoméricamente superior a la del baseline.

Las métricas de GMM son inferiores en las tres dimensiones, lo cual requiere interpretación cuidadosa. GMM opera con 5 clusters en lugar de 3, lo que matemáticamente reduce la compacidad individual de cada grupo al dividir el espacio en regiones más pequeñas. Comparar sus métricas directamente con Spectral Clustering o K-Means no es del todo justo — son granularidades distintas. Lo relevante es que GMM identificó estructura adicional dentro del mundo en desarrollo que los otros métodos agruparon como un único perfil, y esa distinción tiene valor interpretativo independientemente de las métricas internas.

En términos generales, los valores de Silhouette en torno a 0.27 reflejan la naturaleza continua del desarrollo humano: los países no forman grupos perfectamente separados sino que se distribuyen a lo largo de un espectro, lo que inevitablemente limita el valor máximo alcanzable por estas métricas.

9.2. Métricas externas — Validación con HDI

La validación externa compara los clusters descubiertos contra el HDI 2015 del UNDP, utilizando dos métricas ajustadas para distintas granularidades: el Índice de Rand Ajustado (ARI), que mide la similitud entre dos particiones ajustando por azar con rango $[-1, 1]$, y la Información Mutua Normalizada (NMI), que cuantifica la información compartida entre los clusters y las etiquetas reales con rango $[0, 1]$.

Cuadro 7: Métricas externas vs. HDI 2015 (UNDP)

Algoritmo	k	ARI $\uparrow$	NMI $\uparrow$	Países
Spectral Clustering	3	0.4525	0.5586	157
GMM	5	0.3854	0.5398	157

Spectral Clustering obtiene $ARI = 0.4525$ y $NMI = 0.5586$, indicando una alineación significativa con la clasificación oficial del UNDP. Esto significa que el clustering descubrió, de forma completamente no supervisada, una estructura consistente con la que organismos internacionales construyeron con metodologías propias y variables adicionales. La tabla de contingencia confirma esto: el cluster subdesarrollado está compuesto íntegramente por países de categoría Low y Medium del HDI, mientras que el cluster desarrollado concentra casi exclusivamente países Very High.

GMM obtiene $ARI = 0.3854$ y $NMI = 0.5398$. Aunque numéricamente inferior, es importante considerar que GMM compara 5 clusters contra 4 categorías HDI, lo que estructuralmente dificulta la alineación perfecta. El valor de NMI de 0.5398 indica que GMM captura más de la mitad de la información contenida en la clasificación HDI, lo cual es un resultado sólido dado que opera con una granularidad diferente.

El límite superior alcanzable por ambos algoritmos es aproximadamente $ARI \approx 0.45\text{--}0.50$. Este techo no refleja una limitación de los algoritmos sino una limitación del dataset: la variable de educación — uno de los tres pilares del HDI junto a salud e ingreso — no está disponible. Sin esa dimensión, el clustering no puede reproducir perfectamente la separación entre las categorías High y Very High del HDI, que se diferencian principalmente por indicadores educativos.




Figura 4: Tabla de contingencia y composición HDI por cluster.

10. Discusión

Los resultados confirman que el clustering no supervisado es capaz de descubrir estructura de desarrollo humano real. Spectral Clustering logró $ARI = 0.4525$ respecto al HDI oficial del UNDP, una alineación significativa considerando que ambas clasificaciones fueron construidas de forma independiente y con variables parcialmente distintas.

La elección de Spectral Clustering resultó determinante por su robustez ante outliers, propiedad que resolvió un problema concreto que colapsó todos los métodos jerárquicos evaluados. GMM complementó el análisis identificando un subgrupo de países con baja renta e inflación extrema, distinción geopolíticamente relevante que Spectral no captura. Que BIC eligiera $n = 5$ de forma autónoma, y que forzar $n = 3$ produjera resultados inferiores en todas las métricas, valida que esa granularidad adicional refleja señal real y no ruido.

El límite del ARI ($\approx 0,45$) no indica fallo de los algoritmos sino ausencia de la variable educación, pilar del HDI no disponible en el dataset.

11. Conclusiones

1. Spectral Clustering identificó tres perfiles globales con $ARI = 0.4525$, confirmando que el clustering capturó estructura de desarrollo real sin usar etiquetas.
2. GMM reveló cinco perfiles, destacando un subgrupo de países con inestabilidad macroeconómica severa estadísticamente validado por BIC.
3. Las decisiones de preprocesamiento tuvieron impacto directo y medible sobre la calidad del clustering.
4. El techo del ARI alcanzable con este dataset está limitado por la ausencia de indicadores educativos.

Referencias

- [1] HELP International (2020). *Country-Level Socioeconomic & Health Data*. Kaggle. <https://www.kaggle.com/datasets/rohan0301/unsupervised-learning-on-country-data>
- [2] UNDP (2015). *Human Development Report 2015*. United Nations Development Programme. <https://hdr.undp.org/content/human-development-report-2015>
- [3] Roser, M. et al. (2023). *Human Development Index*. Our World in Data. <https://ourworldindata.org/human-development-index>
- [4] Von Luxburg, U. (2007). A tutorial on spectral clustering. *Statistics and Computing*, 17(4), 395–416.
- [5] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR*, 12, 2825–2830.
- [6] Van der Maaten, L. & Hinton, G. (2008). Visualizing data using t-SNE. *JMLR*, 9, 2579–2605.