

Clustering de Países:

Mapeando el Desarrollo

Maestría en Inteligencia Artificial — FIUNA

César Núñez

Proyecto Final — Aprendizaje No Supervisado



El Dataset: Country-Level Socioeconomic & Health Data.

167 Países. 9 Indicadores. Cero Etiquetas.

Variable	Descripción	Unidad
child_mort	Mortalidad infantil (menores de 5 años)	muertes / 1.000 nacidos vivos
exports	Exportaciones de bienes y servicios	% del PIB per cápita
health	Gasto en salud	% del PIB per cápita
inflation	Inflación anual	%
life_expec	Esperanza de vida	años
total_fer	Tasa de fertilidad total	hijos por mujer
gdpp	PIB per cápita (estándar internacional)	USD

Hallazgos que guiaron el preprocesamiento

1

El Eje del Desarrollo

child_mort y life_expec: $r = -0.89$.

2


Redundancia Económica

income y gdp: $r = 0.90$

3

Variable sin Señal

imports: $r = 0.05$ con esperanza de vida.



Preprocesamiento

1

Selección de variables

Eliminamos imports ($r=0.05$) e income ($r=0.90$ con gdp). Retenemos 7 variables esenciales.

2

Transformación log1p

gdpp: sesgo $2.22 \rightarrow 0.01$. child_mort: $1.45 \rightarrow 0.07$.
Distribuciones simétricas.

3

Capping al percentil 95

8 países outliers limitados al p95. Los 167 países se preservan en el análisis.

4

StandardScaler

Media = 0, std = 1. Ninguna variable domina por su magnitud numérica.

Algoritmos utilizados

BASELINE

K-Means (k=3)

Asume clusters esféricos de igual varianza. Referencia comparativa — no es algoritmo principal.

PRINCIPAL

Spectral Clustering (k=3)

Construye un grafo de similitud entre países y clusteriza en el espacio espectral. Captura geometrías no convexas y es robusto ante valores extremos.

PRINCIPAL

GMM — Gaussian Mixture Models (n=5)

Modela cada cluster como una distribución gaussiana. Asigna a cada país una probabilidad de pertenencia a cada grupo — no una etiqueta binaria.

Los 3 Mundos, según el grafo matemático

SUBDESARROLLADO

39 países

Mort. infantil **96.8**

Esperanza de vida **59.0 años**

PIB per cápita **\$939**

Fertilidad **5.17**

*Tanzania, Burkina Faso, Malawi,
Mozambique, Mali, Uganda...*

EN DESARROLLO

76 países

Mort. infantil **29.9**

Esperanza de vida **71.0 años**

PIB per cápita **\$7.664**

Fertilidad **2.66**

*Bolivia, Paraguay, Jamaica, Egipto,
Azerbaijan...*

DESARROLLADO

52 países

Mort. infantil **6.6**

Esperanza de vida **78.6 años**

PIB per cápita **\$29.729**

Fertilidad **1.70**

*Finlandia, Suecia, Polonia, Corea
del Sur, UK...*

La anomalía de la inestabilidad extrema

Perfil	child_mort	gdpp	inflation	n
Subdesarrollado	99.8	\$735	7.0%	32
Subd. c/ inestabilidad ★	92.5	\$3.736	31.3%	9
En desarrollo	37.7	\$3.412	8.8%	41
En desarrollo alto	12.4	\$12.042	7.0%	56
Desarrollado	4.2	\$44.607	1.5%	29

★ Hallazgo clave de GMM:

Nigeria, Yemen, Angola, Sudán — inflación del 31.3%, cuatro veces mayor que el resto de países subdesarrollados. Esta distinción es invisible para Spectral Clustering. BIC eligió $n=5$ de forma autónoma; forzar $n=3$ dio peores métricas.

Compacidad y separación de los clusters

Las métricas internas evalúan calidad sin información externa: Silhouette mide separación, Davies-Bouldin penaliza clusters cercanos, CH evalúa dispersión inter/intra-cluster.

Algoritmo	k	Silhouette ↑	Davies-Bouldin ↓	Calinski-Harabasz ↑
K-Means (baseline)	3	0.2717	1.2844	95.96
Spectral Clustering	3	0.2718	1.2378	92.07
GMM	5	0.1846	1.5426	60.94

Clustering vs. HDI real del UNDP (2015)

HDI = Índice de Desarrollo Humano (Human Development Index) | ARI = Adjusted Rand Index | NMI = Normalized Mutual Information
HDI 2015 seleccionado por coherencia temporal con el dataset (~2014-2016).


Algoritmo	k	ARI ↑	NMI ↑
Spectral Clustering	3	0.4525	0.5586
GMM	5	0.3854	0.5398

El cluster subdesarrollado de Spectral agrupa 100% países Low/Medium del HDI. El cluster desarrollado concentra el 94% Very High — sin haber utilizado ninguna etiqueta durante el proceso.


Clustering vs. HDI real del UNDP (2015)

Ground Truth vs. Algoritmos de Clustering — Espacio t-SNE


Ground Truth
HDI 2015 (UNDP)



Spectral Clustering
k=3 | ARI = 0.4525



GMM
n=5 | ARI = 0.3854



Conclusiones

1

Validación No Supervisada

Spectral Clustering descubrió estructura de desarrollo real ($ARI=0.45$) sin haber utilizado una sola etiqueta durante el proceso.

2

Robustez contra el Ruido

Spectral sorteó el colapso por outliers que arruinó todos los métodos jerárquicos evaluados (Ward, complete, average).

3

El Lente Micro — GMM

Las asignaciones blandas revelaron la inestabilidad macroeconómica como fractura geopolítica propia, invisible para Spectral.

4

El Límite de los Datos

El techo $ARI \approx 0.45$ no es un fallo — es la ausencia de Educación, el pilar del HDI no disponible en el dataset.

Gracias

¿Preguntas?

César Núñez

Maestría en Inteligencia Artificial — FIUNA

github.com/CANM17/country-data